

北京交通大学

硕士专业学位论文

论文题目

论文英文题目

作者：XXXX

导师：XXXX

北京交通大学

2026 年 7 月

学位论文版权使用授权书

本学位论文作者完全了解北京交通大学有关保留、使用学位论文的规定。特授权北京交通大学可以将学位论文的全部或部分内容编入有关数据库进行检索，提供阅览服务，并采用影印、缩印或扫描等复制手段保存、汇编以供查阅和借阅。同意学校向国家有关部门或机构送交论文的复印件和磁盘。学校可以为存在馆际合作关系的兄弟高校用户提供文献传递服务和交换服务。

（保密的学位论文在解密后适用本授权说明）

学位论文作者签名：

导师签名：

签字日期： 年 月 日

签字日期： 年 月

日

学校代码：10004

密级：公开

北京交通大学

硕士专业学位论文

论文题目

论文英文题目

作者姓名：XXXX

学 号：XXXX

导师姓名：XXXX

职 称：XXXX

专业学位类别（领域）：XXXX

学位级别：硕士

北京交通大学

2026 年 7 月

致谢

[内容为小四号宋体。]放置在摘要页前，对象包括：1) 国家科学基金，资助研究工作的奖学金基金，合同单位，资助或支持的企业、组织或个人。2) 协助完成研究工作和提供便利条件的组织或个人。3) 在研究工作中提出建议和提供帮助的人。4) 给予转载和引用权的资料、图片、文献、研究思想和设想的所有者。5) 其他应感谢的组织和个人。

摘要

随着安卓应用生态的快速发展,移动应用已广泛应用于社交通信、移动支付和生活服务等领域,安卓恶意软件对用户隐私、设备安全和应用市场秩序构成了持续威胁。静态分析无需实际运行应用,具有检测效率高、部署成本低和适合大规模筛查等优点。近年来,综合利用应用程序编程接口(Application Programming Interface, API)调用序列、程序调用图和应用清单文件(AndroidManifest.xml,以下简称Manifest)的多模态检测方法逐渐受到关注。然而,三类模态来源于不同的解析过程,其信息完整程度、模型可见范围和判别能力可能存在差异,不同模态分支也可能对同一样本给出相互矛盾的判断。现有的特征拼接、固定加权和常规概率融合方法难以根据样本情况调整不同模态的作用,也缺少对低可信检测结果的风险控制能力。针对上述问题,本文开展面向安卓恶意软件检测的多模态可信融合研究,主要研究内容如下。

(1) 针对固定融合方法难以反映样本级模态差异的问题,提出基于可观测证据的三模态可信度评估方法。该方法从静态解析结果和模型输入状态中提取能够反映模态信息质量及模态间支持关系的证据,并结合各模态分支的整体判别能力,评估不同模态在当前样本中的可信程度,为后续动态调整各模态的作用提供依据。

(2) 针对不同模态判断冲突可能降低融合结果可靠性的问题,提出面向模态冲突的可信证据融合方法。该方法为各模态分支建立包含类别支持程度和预测不确定程度的证据表示,并根据模态可信度削弱低可信证据的作用;在融合过程中,将不同模态之间无法形成一致判断的部分保留为不确定性,避免冲突证据被直接转化为过强的类别判断。

(3) 针对低可信样本被强制分类可能增加检测风险的问题,提出类别条件共形拒识方法。该方法综合融合结果的类别概率和多模态冲突程度,分别建立良性类和恶意类的判断标准,使模型能够自动接受具有明确判断依据的样本,并拒识证据不足或类别难以确定的样本,为后续人工复核或其他检测流程提供入口。

实验结果表明,本文方法在常规测试集上具有较好的检测性能,并在跨模态支持较弱、模态判断冲突和低可信样本子集上表现出较好的概率校准与风险控制能力。

关键词: 安卓恶意软件检测;多模态可信融合;模态可信度评估;证据学习;模态冲突;共形预测;选择性拒识

ABSTRACT

With the rapid development of the Android application ecosystem, mobile applications have been widely used in social communication, mobile payment, and daily services. Meanwhile, Android malware continues to threaten user privacy, device security, and the security of application markets. Static analysis does not require applications to be executed and is therefore efficient, inexpensive to deploy, and suitable for large-scale screening. In recent years, multimodal detection methods that combine Application Programming Interface (API) call sequences, program call graphs, and AndroidManifest.xml declarations have attracted increasing attention. However, these modalities are obtained through different analysis procedures and may differ in information completeness, model-visible content, and discriminative ability. Different modality branches may also produce conflicting predictions for the same application. Existing feature concatenation, fixed weighting, and conventional probability fusion methods cannot adequately adjust the contribution of each modality according to individual samples. They also provide limited control over the risks associated with unreliable predictions. To address these problems, this thesis investigates trustworthy multimodal fusion for Android malware detection. The main contributions are as follows.

First, an observable-evidence-based reliability assessment method is proposed for the three modalities. The method extracts evidence reflecting modality quality and cross-modal support from static analysis results and model input states. It further considers the overall discriminative ability of each modality branch to assess the reliability of different modalities for individual samples. The resulting reliability scores provide a basis for dynamically adjusting the contribution of each modality during fusion.

Second, a trustworthy evidence fusion method is proposed to handle conflicting modality predictions. The method represents the output of each modality branch using class support and predictive uncertainty and reduces the influence of unreliable evidence according to the estimated modality reliability. During fusion, evidence that cannot support a consistent decision across modalities is retained as uncertainty instead of being converted directly into strong support for a specific class. This design reduces the adverse influence of unreliable and conflicting evidence on the final decision.

Third, a class-conditional conformal rejection method is proposed for unreliable predictions. By jointly considering the fused class probabilities and the degree of

multimodal conflict, the method establishes separate decision criteria for benign and malicious classes. It automatically accepts samples with sufficient evidence and a clear decision while rejecting samples with insufficient evidence or class ambiguity. Rejected samples can subsequently be processed through manual review or other detection procedures.

Experimental results show that the proposed method achieves competitive detection performance on the standard test set. It also provides improved probability calibration and risk control on subsets with weak cross-modal support, conflicting modality predictions, and unreliable samples.

Keywords: Android malware detection; trustworthy multimodal fusion; modality reliability assessment; evidential learning; modality conflict; conformal prediction; selective rejection

序言

[鼠标左键单击选择该段落，输入替换之。内容为小四号宋体。] 学位论文的序或前言，一般是作者或他人对本篇论文基本特征的简介，如说明研究工作缘起、背景、主旨、目的、意义、编写体例，以及资助、支持、协作经过等；也可以评述和对相关问题发表意见。这些内容也可以在正文引言中说明。

目录

摘要	III
ABSTRACT	IV
序言	VI
1 引言	10
1.1 研究背景与意义	10
1.2 国内外研究现状	11
1.2.1 基于静态特征与传统机器学习的检测方法	11
1.2.2 基于 API 行为建模的检测方法	12
1.2.3 基于图结构语义的检测方法	12
1.2.4 基于多模态融合的检测方法	13
1.2.5 面向可信检测与风险控制的相关研究	14
1.2.6 研究现状总结	14
1.3 论文主要工作	15
1.4 论文内容组织	16
2 相关理论与关键技术	18
2.1 安卓应用结构与静态分析基础	18
2.2 三模态静态特征表示	19
2.2.1 API 调用序列特征	19
2.2.2 程序调用图特征	19
2.2.3 Manifest 声明特征	20
2.3 三模态特征编码方法	20
2.3.1 基于 Transformer 的 API 序列编码	21
2.3.2 基于 GATv2 的调用图编码	21
2.3.3 Manifest 声明特征编码	22
2.4 多模态学习与融合	22
2.5 模态可信度评估基础	23
2.6 证据学习与主观逻辑	23
2.7 多模态证据冲突与组合	24

2.8 选择性预测与共形预测	25
2.9 本章小结	26
3 基于可观测证据的三模态可信度评估方法	27
3.1 问题描述与总体框架	27
3.2 可观测证据构建	28
3.2.1 模态可用性	28
3.2.2 模态完整性	28
3.2.3 模态可见比例	30
3.2.4 跨模态支持与不一致关系	30
3.2.5 分支整体判别能力先验	32
3.3 三模态可信度估计	32
3.3.1 模态证据向量	33
3.3.2 单调可靠性校准	33
3.3.3 模型可见性修正与综合可信评分	34
3.4 本章方法分析	35
3.5 本章小结	36
4 面向模态冲突的可信证据融合方法	37
4.1 问题描述与总体框架	37
4.2 三模态分支的证据表示	38
4.3 基于模态可信评分的证据折扣	39
4.4 组合前模态冲突的计算	39
4.5 基于 YAGER 规则的三模态证据融合	40
4.6 训练目标	41
4.7 本章方法分析	42
4.8 本章小结	42
5 面向低可信预测的类别条件拒识方法	44
5.1 问题描述与总体框架	44
5.2 融合概率与模态冲突共同约束的非一致性分数	45
5.3 类别条件共形校准	46
5.4 共形预测集合与拒识规则	46
5.5 本章方法分析	47
5.6 本章小结	48

7 总结与展望	48
7.1 工作小结	48
7.2 不足与展望	50
参考文献	53
附录 A	56
索引	57
作者简历及攻读硕士/博士学位期间取得的研究成果	58
独创性声明	59
学位论文数据集	60

1 引言

本章围绕安卓恶意软件检测的研究背景、国内外研究现状和本文研究内容展开。首先，分析安卓应用生态面临的恶意软件威胁以及静态检测的应用价值；其次，从传统静态特征、API 行为、程序图、多模态融合和可信检测五个方面梳理相关研究；在此基础上，总结现有方法的不足并明确本文研究问题；最后，介绍本文的主要工作和全文结构。

1.1 研究背景与意义

随着移动互联网和安卓（Android）应用生态的快速发展，移动应用已广泛用于社交通信、移动支付、在线办公和生活服务等领域。移动终端在处理大量个人信息、身份凭证和敏感权限的同时，也成为恶意软件攻击的重要目标。开放的应用分发渠道和规模庞大的第三方应用生态，进一步增加了恶意应用传播和变种扩散的可能性。谷歌（Google）公司发布的 2025 年度安卓与 Google Play 应用商店生态安全总结^[1]显示，Google Play 在 2025 年阻止了超过 175 万个违反政策的应用发布，并封禁了 8 万多个试图发布有害应用的开发者账号。卡斯基（Kaspersky）发布的 2025 年度移动威胁报告^[2]显示，其安全产品全年阻止了 14059465 次涉及恶意软件、广告软件或其他不受欢迎移动软件的攻击。这些数据表明，移动恶意软件及相关风险仍持续影响安卓应用生态，研究高效、稳定且能够反映预测可信程度的检测方法具有现实意义。

安卓恶意软件检测通常采用动态分析、静态分析或二者结合的方式。动态分析通过运行应用并监测其运行时行为发现恶意活动，能够获得真实执行过程中产生的系统调用、网络通信和资源访问等信息，但存在分析时间较长、运行成本较高、执行路径覆盖不足以及可能受到反沙箱机制干扰等问题。静态分析不需要运行应用，而是通过解析安卓应用安装包（Android Package, APK）中的代码和配置文件提取检测特征，具有分析效率高、部署成本低和适合大规模应用筛查等优点。因此，静态检测在应用商店审核、终端安全防护和大规模恶意样本分析中具有较高的应用价值。

在安卓恶意软件静态检测中，应用程序编程接口（Application Programming Interface, API）调用序列、程序调用图和应用清单文件（AndroidManifest.xml，以下简称 Manifest）声明信息是三类常用特征。API 调用序列能够反映应用访问系统服务和敏感资源的行为过程；程序调用图能够描述方法之间的调用结构和依赖关

系；Manifest 声明信息则提供权限、组件、意图过滤器和应用配置等信息。三类模态分别从行为顺序、程序结构和应用声明三个角度描述安卓应用，具有一定的互补性。综合利用这些信息，有助于减少单一特征描述范围有限所带来的影响。

然而，多模态信息的增加并不意味着所有模态在每个样本中都具有相同的作用。三类模态来源于不同的解析过程，其信息完整程度、模型可见范围和整体判别能力可能存在差异。例如，大量框架调用和第三方库调用可能在 API 序列中引入背景信息；调用图构建不完整或图规模过大可能影响关键调用关系的表达；Manifest 中的权限冗余和未实际使用的声明也可能使声明信息与代码行为不完全一致。此外，不同模态分支在面对同一样本时可能得出不同结论。若仍采用固定方式融合各模态，信息较弱或判断冲突的分支可能对最终结果产生不利影响。

现有多模态检测方法主要关注不同特征的组合及其对分类性能的提升，部分方法采用特征拼接、固定加权或常规概率融合，难以根据单个样本的证据状态调整各模态的作用。当不同模态的有效信息存在差异或分支判断相互冲突时，模型仍可能给出过于确定的分类结果。同时，常规检测模型通常要求对全部样本输出良性或恶意类别，缺少对证据不足和判断不明确样本的处理机制。因此，如何评估不同模态在当前样本中的可信程度，如何在融合过程中保留并处理模态冲突，以及如何控制低可信预测带来的风险，是多模态安卓恶意软件检测中值得研究的问题。

围绕上述问题开展研究，一方面有助于提高多源静态信息的利用效率，使模型能够根据不同样本的证据状态合理调整各模态的作用；另一方面，可以使检测模型在输出类别的同时反映预测依据是否充分，并为难以自动判断的样本提供后续复核入口，从而提升静态检测方法在实际安全场景中的可信性。

1.2 国内外研究现状

安卓恶意软件检测是移动安全领域的重要研究方向。根据特征来源和建模方式，现有研究可分为基于静态特征与传统机器学习的方法、基于 API 行为建模的方法、基于图结构语义的方法、基于多模态融合的方法以及面向可信检测与风险控制的方法。下面分别进行介绍。

1.2.1 基于静态特征与传统机器学习的检测方法

早期安卓恶意软件检测主要依赖人工构建的静态特征和传统机器学习模型。此类方法通常从 APK 中提取权限、组件、意图（Intent）、API 调用、网络地址和字符串等信息，再使用支持向量机（Support Vector Machine, SVM）、决策树或随机森林等分类器进行检测。

Wu 等^[3]提出 DroidMat，通过提取 Manifest 中的权限、组件、Intent 和字节码中的 API 调用特征识别恶意应用。Aafer 等^[4]提出 DroidAPIMiner，从安卓应用中挖掘 API 调用频率及相关 API 级特征，以构建轻量级检测模型。Arp 等^[5]提出 Drebin，对权限、组件、Intent、API 调用和网络地址等多类静态特征进行联合建模，并利用线性分类模型实现恶意软件检测和特征解释。

传统静态特征方法具有提取速度快、计算开销较低和便于解释等优点，为后续安卓恶意软件检测研究奠定了基础。但权限、组件等声明特征可能受到权限冗余和第三方库的影响，API 频率等浅层代码特征也难以表达调用顺序和行为上下文。因此，研究者开始利用行为序列和深度学习方法提升特征表达能力。

1.2.2 基于 API 行为建模的检测方法

API 调用反映应用使用系统服务和访问敏感资源的方式。与 API 是否出现或调用频率相比，API 调用序列保留了部分行为顺序信息，能够描述更加具体的调用模式。随着深度学习的发展，研究者开始利用序列模型自动学习 API 行为特征。

Mariconti 等^[6]提出 MaMaDroid，将 API 调用抽象到包级或家族级，利用马尔可夫链描述 API 类别之间的转移关系，从而增强模型对安卓接口演化的适应能力。Karbab 等^[7]提出 MalDozer，直接从 Dalvik 可执行文件（Dalvik Executable, DEX）中提取 API 方法调用序列，并使用神经网络学习恶意行为模式，实现恶意软件检测和家族分类。

API 行为建模能够较好地描述调用顺序和局部行为模式，但对方法之间的结构关系和调用路径表达有限。同时，静态 API 序列仅包含解析工具能够观察到的调用信息，其有效范围会受到代码结构和提取过程的影响。程序图建模由此成为补充序列信息的重要方向。

1.2.3 基于图结构语义的检测方法

程序图能够表示方法、API 和组件之间的结构关系。现有研究使用函数调用图、控制流图、数据依赖图和异构信息网络等形式刻画安卓应用，并通过图相似性、图统计特征或图神经网络完成检测。

Hou 等^[8]提出 HinDroid，将应用、API 及其关系建模为异构信息网络，并利用 API 之间的高阶语义关系识别恶意应用。Zhang 等^[9]提出 DroidSIFT，通过构建加权上下文 API 依赖图并计算图相似性，描述恶意行为的结构语义。Wu 等^[10]提出 MalScan，将函数调用图视为网络结构，利用敏感 API 的中心性特征实现具有较高扩展性的恶意软件检测。

国内研究也对图结构检测进行了探索。吴月明等^[11]提出 SriDroid，对函数调用图进行抽象，并利用图卷积网络（Graph Convolutional Network, GCN）学习图结构表示。杨宏宇等^[12]提出 DroidSA，通过 API 聚类 and 调用图优化提取较稳定的 API 上下文信息，以缓解安卓框架和恶意软件演化对检测模型的影响。

图结构方法能够补充序列特征缺少的结构信息，但其有效性依赖调用关系的构建质量。调用边缺失、节点特征不完整和图规模限制均可能影响图表示。此外，复杂图分析通常具有较高的计算开销。因此，将图结构与其他静态信息结合，成为进一步提升检测能力的重要思路。

1.2.4 基于多模态融合的检测方法

单一静态特征只能从特定角度描述应用，难以同时覆盖行为顺序、程序结构和应用声明。为获得更加全面的应用表示，研究者开始融合 Manifest、API、程序图、字节码和反编译代码等多类信息。

Ullah 等^[13]提出 Droid-MCFG，将 Manifest 特征与控制流图中的 API 序列结合，并使用多头时序卷积网络完成检测。Li 等^[14]将反编译代码文本和二进制代码表示作为不同模态，结合预训练模型和跨模态融合策略学习应用特征。Trung 等提出的 DMLDroid 预印本^[15]融合权限与 Intent、DEX 表示和由调用图派生的 API 序列，并比较多种融合策略在代码变换和对抗扰动下的表现。MIPDroid^[16]从保持模态特有信息的角度出发，融合权限、API 和 DEX 图像表示，并利用动态融合减轻模态质量变化和表征同质化的影响。

上述研究表明，多模态融合能够利用不同信息来源之间的互补关系，已成为安卓恶意软件检测的重要方向。现有方法也逐渐由简单特征拼接发展到跨模态交互和动态权重学习。但部分方法主要根据特征表示或预测结果隐式学习融合关系，对静态解析过程中可直接观察到的模态状态利用不足；同时，对 API 与调用图的结

构对应关系、Manifest 声明与代码行为之间的语义不一致，以及分支判断冲突的联合处理仍有进一步研究空间。

1.2.5 面向可信检测与风险控制的相关研究

随着机器学习模型在安全检测中的应用不断深入，研究重点逐渐由单纯提高分类准确率扩展到不确定性估计、可信融合和预测风险控制。对于恶意软件检测而言，模型不仅需要给出分类结果，还应反映该结果是否具有充分依据。

在不确定性建模方面，Sensoy 等^[17]提出证据深度学习（Evidential Deep Learning, EDL）方法，将神经网络输出转换为狄利克雷分布参数，使模型能够同时表示类别支持和预测不确定性。在多视图学习方面，Han 等^[18]提出可信多视图分类（Trusted Multi-View Classification, TMC）方法，将不同视图的输出表示为主观逻辑意见，并利用登普斯特-沙弗证据理论（Dempster-Shafer Evidence Theory）进行组合，从而在多视图分类中同时利用类别证据和不确定性信息。

不同视图的预测并不总是一致。针对冲突多视图数据，Xu 等^[19]提出可靠冲突多视图学习任务，并构建证据冲突多视图学习方法，通过视图证据和冲突意见聚合同时输出分类结果及其可靠程度。该研究说明，多源信息融合不能只利用不同视图之间的一致信息，还需要保留并处理相互矛盾的判断。

在预测风险控制方面，Geifman 等^[20]研究深度神经网络的选择性分类，使模型能够拒绝处理预测风险较高的样本，从而在自动接受比例与接受样本风险之间进行权衡。随后提出的选择性网络（SelectiveNet）^[21]将分类和拒识纳入统一训练过程。共形预测（Conformal Prediction）则利用独立校准数据确定非一致性阈值，在一定条件下为预测集合提供有限样本覆盖性质。

在恶意软件检测领域，Jordaney 等提出 Transcend 框架^[22]，利用统计检验和共形思想识别恶意软件分类模型可能出现的概念漂移，为不可靠预测和模型失效预警提供了新的研究视角。这些工作表明，对于安全检测任务，仅报告分类准确率并不足以全面评价模型，还需要考察预测概率是否可靠、不同信息来源是否一致，以及高风险样本能否被及时识别。

1.2.6 研究现状总结

现有安卓恶意软件检测已经形成从人工静态特征、API 行为序列、程序图表示到多模态深度学习的发展路线。传统静态特征方法具有较高效率和较好的可解释性，但对复杂行为的表达能力有限；API 序列方法能够描述调用顺序，却难以完整表示程序结构；图结构方法能够刻画调用关系，但依赖图构建质量且计算开销较高；多模态方法能够综合不同来源的信息，但如何判断各模态在具体样本中的参考价值仍是影响融合质量的重要问题。

可信多视图学习、证据学习和选择性预测为解决上述问题提供了理论基础，但将这些方法应用于安卓恶意软件静态多模态检测时，仍存在以下不足。

(1) 部分融合方法主要依据特征表示或预测结果学习融合权重，对静态解析过程中可以直接观察到的模态完整性、运行时可见比例和跨模态支持关系利用不足，难以明确说明某一模态为何在当前样本中可信或不可信。

(2) 不同模态分支可能对同一样本形成冲突判断。常规概率平均或归一化融合可能削弱冲突本身所反映的风险，使模型在模态意见分歧较大时仍输出较为确定的类别。

(3) 多数安卓恶意软件检测方法仍以对全部样本进行强制分类为目标，缺少针对证据不足和类别歧义样本的拒识机制，也较少分别考察良性类和恶意类的预测集合覆盖情况。

针对上述不足，本文以 API 调用序列、程序调用图和 Manifest 声明信息为三类静态模态，围绕模态可信度评估、冲突证据融合和低可信预测拒识开展研究，形成从模态状态评估、证据组合到风险控制的多模态可信检测流程。

1.3 论文主要工作

本文面向安卓恶意软件静态多模态检测中模态作用难以区分、分支判断可能冲突以及低可信样本被强制分类等问题，研究多模态可信融合与预测风险控制方法。主要工作如下。

(1) 针对固定融合方式难以反映不同样本中模态信息差异的问题，提出基于可观测证据的三模态可信度评估方法。该方法利用静态解析结果和模型输入状态构建模态质量及跨模态支持证据，并结合各分支的整体判别能力，评估 API、调用图和 Manifest 模态在当前样本中的可信程度，为后续融合提供可解释的动态依据。

(2) 针对不同模态判断冲突可能降低融合结果可靠性的问题，提出面向模态冲突的可信证据融合方法。该方法为三个模态分支建立包含类别支持和预测不确定性的证据表示，并根据模态可信度调整各分支证据的作用；对于不同模态之间无

法形成一致结论的部分, 将其保留为融合不确定性, 避免冲突信息被直接转化为过强的类别判断。

(3) 针对证据不足或类别难以确定的样本被强制分类可能增加检测风险的问题, 提出类别条件共形拒识方法。该方法综合融合类别概率和模态冲突信息, 分别建立良性类和恶意类的判断标准, 使模型能够自动接受具有明确判断依据的样本, 并拒识难以形成唯一结论的样本, 为人工复核或其他检测流程提供入口。

1.4 论文内容组织

本文围绕安卓恶意软件静态检测中的多模态可信融合问题展开研究, 全文共分为七章, 各章内容如下。

第一章为引言。介绍安卓恶意软件检测的研究背景与意义, 梳理静态特征、API 行为、程序图、多模态融合和可信检测相关研究, 总结现有方法的不足, 并说明本文的主要工作和论文结构。

第二章为相关理论与关键技术。介绍安卓应用结构与静态分析基础, 以及 API 调用序列、程序调用图和 Manifest 声明信息的表示方法; 随后介绍多模态学习、模态可信度评估、证据学习、主观逻辑和选择性拒识等相关理论。

第三章为基于可观测证据的三模态可信度评估方法。构建模态可用性、模态完整性、模型可见比例和跨模态关系等可观测证据, 并结合分支整体判别能力和单调可靠性校准, 得到三个模态的样本级可信评分。

第四章为面向模态冲突的可信证据融合方法。将各模态分支输出转换为带有不确定性的证据表示, 根据模态可信评分完成证据折扣, 并采用冲突保留的证据组合方法形成最终分类结果和融合不确定性。

第五章为面向低可信预测的类别条件共形拒识方法。利用融合类别概率和证据组合前的模态冲突构造类别非一致性分数, 通过独立校准数据确定类别条件阈值, 并根据共形预测集合决定接受或拒识。

第六章为实验设计与结果分析。介绍数据集、实验环境、评价指标和对比方法, 并通过常规检测、可信融合对比、模块分析、自然困难子集和受控扰动等实验评价本文方法。

第七章为总结与展望。总结本文的研究内容和实验结论, 分析现有工作的局限, 并对后续研究方向进行展望。

本文的组织结构如图 1-1 所示：




图 1-1 论文组织结构

Figure 1-1 Organization of the paper

2 相关理论与关键技术

本章介绍本文研究涉及的理论基础和关键技术。首先说明安卓应用的基本结构及静态分析对象，并介绍 API 调用序列、程序调用图和 Manifest 声明信息三类静态特征；其次，结合本文的模型结构，介绍 Transformer、图注意力网络和前馈神经网络等编码方法；随后说明多模态融合、模态可信度评估、证据学习和证据冲突处理的基本原理；最后介绍选择性预测和共形预测，为后续章节的方法设计提供理论基础。

2.1 安卓应用结构与静态分析基础

安卓应用通常以安卓应用安装包（Android Package, APK）的形式发布。APK 本质上是一种压缩文件，内部包含应用运行所需的字节码、资源、配置和签名等信息。与本文研究相关的主要内容包括 Dalvik 可执行文件（Dalvik Executable, DEX）和应用清单文件 AndroidManifest.xml。

DEX 文件保存应用编译后的类、方法、字段和方法调用等字节码信息。通过对 DEX 文件进行静态解析，可以获得 API 调用、方法调用关系和程序结构等代码侧特征。AndroidManifest.xml 用于描述应用包名、权限、组件、意图过滤器和系统版本要求等声明信息。Manifest 声明不能完整表示应用的实际代码行为，但能够反映应用申请的系统能力、对外暴露的组件和基本配置信息，是代码侧特征的重要补充。

静态分析不需要运行应用，而是直接从 APK 中提取检测特征，具有分析效率高、部署成本低和适合大规模筛查等优点。其局限在于只能观察静态解析工具能够恢复的信息，难以直接获得运行时动态加载、反射调用和环境交互等行为。本文不以恢复被隐藏的运行时行为为研究目标，而是在现有静态解析结果基础上，研究不同模态信息的可信度评估、证据融合和低可信结果处理方法。

对于一个 APK 样本，本文使用 API 调用序列、程序调用图和 Manifest 声明信息三类静态模态，其输入表示为：

$$\mathbf{x} = \{\mathbf{x}_{\text{api}}, \mathbf{x}_{\text{graph}}, \mathbf{x}_{\text{man}}\} \quad (2-1)$$

其中， $\mathbf{x}_{\text{api}}$ 表示 API 调用序列特征， $\mathbf{x}_{\text{graph}}$ 表示程序调用图特征， $\mathbf{x}_{\text{man}}$ 表示 Manifest 声明特征。三类模态分别从代码行为、程序结构和应用声明三个角度描述安卓应用。其提取过程如图 2-1 所示。




图 2-1 模态特征提取示意图

Figure 2-1 APK Static Analysis and Tri-modal Feature Extraction

2.2 三模态静态特征表示

2.2.1 API 调用序列特征

安卓应用通过调用系统接口、框架接口和第三方库接口实现具体功能。部分 API 与隐私读取、短信操作、网络通信、文件访问和设备信息获取等行为密切相关，因此 API 调用是安卓恶意软件检测中常用的静态行为特征。

设从样本中提取到的 API 调用序列为：

$$A = (a_1, a_2, \dots, a_n) \quad (2-2)$$

其中， a_i 表示第 i 个 API 调用， n 表示提取到的调用数量。与只记录 API 是否出现或调用频率的词袋表示相比，序列表示保留了调用事件之间的先后关系，便于模型学习局部行为模式和上下文信息。

API 调用序列的有效范围取决于静态解析结果和模型输入长度。当序列过长时，编码器只能处理其中一部分调用事件；当静态解析能够观察到的调用较少时，序列提供的行为信息也会相应减少。因此，API 模态不仅需要进行行为表示学习，还需要记录其信息完整程度和实际进入编码器的比例。

2.2.2 程序调用图特征

程序调用图用于描述方法之间的调用关系。与 API 序列主要关注调用顺序不同,调用图能够表示方法之间的结构联系,有助于发现敏感行为所在的调用环境和传播路径。

对于一个 APK 样本,其程序调用图表示为:

$$G = (V, E, X) \quad (2-3)$$

其中, V 为方法节点集合, E 为方法调用边集合, X 表示节点特征矩阵。若方法 v_i 调用了方法 v_j , 则调用图中存在由 v_i 指向 v_j 的有向边。节点特征可包含方法标识、API 语义类别和其他静态属性。

程序调用图能够补充 API 序列缺少的结构信息,但其质量依赖调用关系的构建结果。当节点或调用边未被完整提取、图结构过度碎片化或图规模超过编码器预算时,图模态提供的有效信息可能受到影响。

2.2.3 Manifest 声明特征

Manifest 声明特征主要包括权限、组件、意图过滤器、系统版本和应用配置等信息。其中,权限声明反映应用请求访问的系统资源;组件声明描述活动、服务、广播接收器和内容提供者等应用组成;意图过滤器反映组件能够接收的外部事件或系统广播。

设权限特征向量为 p , 意图过滤器特征向量为 i , 其他声明和统计特征为 s , 则 Manifest 模态可表示为:

$$x_{\text{man}} = [p; i; s] \quad (2-4)$$

Manifest 特征提取成本较低,且不依赖复杂的程序结构恢复,但声明信息与实际代码行为并不总是一致。例如,第三方库可能引入额外权限,部分权限可能被声明但未实际使用,代码侧也可能存在未被声明特征充分反映的行为。因此,Manifest 适合作为代码侧模态的补充,而不宜仅依据声明信息作出最终判断。

2.3 三模态特征编码方法

三类模态的数据结构不同,需要分别使用与其特征形式相适应的编码器。本文采用 Transformer 编码 API 调用序列,采用第二代图注意力网络编码程序调用图,并使用前馈神经网络编码 Manifest 定长向量。

2.3.1 基于 Transformer 的 API 序列编码

Transformer 是一种基于自注意力机制的序列建模网络^[23]。与循环神经网络逐步处理序列不同, Transformer 能够并行计算不同位置之间的关联, 适合从较长的 API 调用序列中提取上下文特征。

对于第 i 个 API 调用, 本文将 API 标识嵌入、API 类型嵌入和位置编码相加, 得到初始表示:

$$h_i^{(0)} = e_i^{\text{api}} + e_i^{\text{type}} + e_i^{\text{pos}} \quad (2-5)$$

其中, e_i^{api} 表示第 i 个 API 标识的嵌入向量, e_i^{type} 表示该 API 所属类型的嵌入向量, e_i^{pos} 表示第 i 个位置对应的位置编码。位置编码用于保留 API 调用的顺序信息, 使模型能够区分相同 API 出现在不同位置时的上下文差异。

设序列表示矩阵为 H , 自注意力机制首先通过可学习矩阵将其映射为查询矩阵 Q 、键矩阵 K 和值矩阵 V , 并计算:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_h}}\right)V \quad (2-6)$$

其中, d_h 为单个注意力头的特征维数。多头注意力在不同子空间中并行计算序列关系, 再将各头输出拼接并进行线性变换。经过多层注意力、前馈网络、残差连接和归一化后, 可获得包含上下文信息的 API 序列表示。

2.3.2 基于 GATv2 的调用图编码

图注意力网络 (Graph Attention Network, GAT) 通过学习邻居节点的重要程度完成图特征聚合。第二代图注意力网络 (Graph Attention Network v2, GATv2) 改进了原有注意力计算形式, 使节点之间的注意力关系具有更强的表达能力^[24]。

设节点 v 在第 l 层的表示为 $h_v^{(l)}$, 其邻居集合为 $N(v)$ 。GATv2 首先根据中心节点与邻居节点的联合表示计算注意力分数, 并在邻居范围内进行归一化:

$$s_{vu}^{(l)} = a^T \text{LeakyReLU}(W^{(l)}[h_v^{(l)} \| h_u^{(l)}]) \quad (2-7)$$

$$\alpha_{vu}^{(l)} = \frac{\exp(s_{vu}^{(l)})}{\sum_{j \in N(v)} \exp(s_{vj}^{(l)})} \quad (2-8)$$

其中, $W^{(l)}$ 和 a 为可学习参数, $\|$ 表示向量拼接, $\alpha_{vu}^{(l)}$ 表示邻居节点 u 对节点 v 的作用程度。节点表示更新为:

$$h_v^{(l+1)} = \sigma \left(\sum_{u \in N(v) \cup \{v\}} \alpha_{vu}^{(l)} W_n^{(l)} h_u^{(l)} \right) \quad (2-9)$$

其中， σ 表示非线性激活函数。经过多层图注意力计算和图级汇聚后，可得到整个程序调用图的表示。

2.3.3 Manifest 声明特征编码

Manifest 模态经过词表映射和统计处理后形成定长向量，适合使用多层前馈神经网络进行编码。设 Manifest 输入为 x_{man} ，其编码表示为：

$$z_{\text{man}} = f_{\text{man}}(x_{\text{man}}) \quad (2-10)$$

其中， $f_{\text{man}}(\bullet)$ 由线性变换、非线性激活和随机失活等操作组成。该编码器将权限、组件、意图过滤器及统计特征映射到与其他模态一致的表示空间，为后续分支分类和多模态融合提供输入。

三模态编码过程如图 2-2 所示。




图 2-2 三模态特征编码过程

Figure 2-2 Encoding Process of the Three Modalities

2.4 多模态学习与融合

多模态学习通过综合不同信息来源，提高模型对研究对象的描述能力。设样本包含 M 个模态，第 m 个模态的编码器为 f_m ，则对应模态表示为：

$$z_m = f_m(x_m), \quad m = 1, 2, \dots, M \quad (2-11)$$

根据融合位置，多模态方法通常可分为特征级融合、决策级融合和证据级融合。特征级融合在编码后拼接不同模态表示：

$$\mathbf{z}_{\text{fusion}} = [\mathbf{z}_1; \mathbf{z}_2; \dots; \mathbf{z}_M] \quad (2-12)$$

拼接后的联合表示由统一分类器完成预测。该方式实现简单，能够学习模态之间的联合特征，但难以直接观察各分支的独立判断。

决策级融合先由各模态分支独立输出类别概率或类别得分，再采用平均、固定加权或动态加权方式组合。该方式能够保留分支预测结果，便于分析不同模态对最终决策的作用。

证据级融合进一步将分支输出表示为带有不确定性的证据，并根据证据来源的可信程度进行调整和组合。与普通概率平均相比，证据级融合不仅需要考虑各分支支持哪个类别，还需要处理分支证据是否充分以及不同分支之间是否存在冲突。本文采用证据级融合作为主要决策方式。

2.5 模态可信度评估基础

多模态融合通常依赖各模态提供的互补信息，但不同模态在具体样本中的参考价值可能存在差异。模态可信度评估的目的，是根据模型能够观察到的信息判断某一模态是否适合以较强作用参与当前样本的融合。

影响模态可信程度的因素可以分为三个层面。第一，模态自身的状态，包括是否成功提取、解析结果是否完整以及输入内容是否有效；第二，模型实际可利用的信息范围，例如长序列和大规模程序图受到编码器输入预算限制后，模型只能接收部分信息；第三，模态与其他信息来源之间的支持关系，例如 API 调用能否与程序调用图节点建立对应关系，Manifest 声明能否与代码行为相互印证。

除样本级状态外，不同模态分支在整个数据集上的判别能力也可能存在差异。一个模态即使当前样本中信息完整，其对应分支的总体分类能力也未必与其他分支相同。因此，可信度评估可以同时结合样本级证据和分支级先验信息。

需要区分的是，模态可信度描述输入信息的参考价值，而分支预测冲突描述模型在类别判断上的分歧。前者可由静态解析状态、模型可见范围和跨模态静态关系估计；后者需要根据各分支的预测证据计算。本文在第 3 章建模模态可信度，在第 4 章处理预测意见冲突，以避免将输入状态与模型输出混为同一概念。

2.6 证据学习与主观逻辑

常规深度分类模型通常使用归一化指数函数 (Softmax) 将类别得分转换为概率。Softmax 概率描述各类别之间的相对大小,但不能单独说明模型是否获得了充分证据。在输入信息不足或样本难以判断时,模型仍可能给出较高的最大类别概率。

证据深度学习通过非负类别证据构造狄利克雷分布,从而同时表示类别倾向和预测不确定性^[17]。设模型对第 k 个类别的原始输出为 o_k ,采用平滑整流函数 (Softplus) 得到非负证据:

$$e_k = \text{softplus}(o_k) \quad (2-13)$$

类别证据对应的狄利克雷参数和总证据强度分别为:

$$\alpha_k = e_k + 1, \quad S = \sum_{k=1}^K \alpha_k \quad (2-14)$$

其中, K 为类别数。根据主观逻辑,可将分支输出表示为由类别支持度 b_k 和整体不确定程度 u 构成的意见:

$$b_k = \frac{e_k}{S}, \quad u = \frac{K}{S}, \quad \sum_{k=1}^K b_k + u = 1 \quad (2-15)$$

当模型获得的类别证据较多时,总证据强度 S 增大,不确定程度 u 减小;当证据不足时, u 相应增大。若各类别采用均匀先验,类别概率期望为:

$$p_k = b_k + \frac{u}{K} = \frac{\alpha_k}{S} \quad (2-16)$$

主观逻辑中的信任折扣允许根据证据来源的可信程度调整一个意见。可信度降低时,分配给具体类别的支持随之减少,减少的部分转入不确定性,而不是转移给相反类别。第4章将在此基础上构建适用于三模态检测的证据折扣和组合方法。

2.7 多模态证据冲突与组合

当多个模态支持相同类别时,其证据可以相互补充;当不同模态分别支持不同类别时,则会形成证据冲突。证据冲突不等同于某个模态一定错误,它表示现有证据无法共同支持唯一类别结论。

在登普斯特-沙弗证据理论中,冲突质量可表示为不同证据源分配给互斥命题的联合质量。对于两个证据源,其冲突程度可概括为:

$$\kappa = \sum_{B \cap C = \emptyset} m_1(B)m_2(C) \quad (2-17)$$

其中, m_1 和 m_2 表示两个证据源的基本概率分配, B 和 C 表示类别命题。当两个证据源主要支持相同类别时,冲突较小;当二者分别支持互斥类别时,冲突增大。

不同证据组合规则对冲突采用不同处理方式。Dempster 规则通过归一化消除空集冲突，并将非冲突证据重新归一化；当证据高度冲突时，该处理可能使融合结果仍具有较高确定性。Yager 规则则将冲突保留在不确定集合中，使融合结果能够反映不同证据源之间的分歧^[25]。本文采用后一种处理思路，并结合模态可信评分完成三模态证据融合。

图 2-3 给出了本文所采用的多模态可信融合基本过程。




图 2-3 多模态可信融合基本过程

Figure 2-3 Basic Process of Trustworthy Multimodal Fusion

2.8 选择性预测与共形预测

常规分类模型要求对所有样本输出唯一类别，但不同样本的预测可靠程度并不相同。选择性预测允许模型拒绝处理难以可靠判断的样本，在自动处理比例与接受样本风险之间进行权衡。被拒识的样本可交由人工复核、动态分析或其他检测流程进一步处理。

共形预测 (Conformal Prediction)^[26] 是一类利用校准数据构造预测集合的方法。其基本过程包括：首先，利用独立校准集计算能够反映样本与候选类别不一致程度的分数；其次，根据校准分数确定阈值；最后，对测试样本的各候选类别分别进行检验，并将通过检验的类别组成预测集合。

预测集合可能出现三种情况：当集合仅包含一个类别时，模型形成唯一类别结论；当集合为空时，说明当前样本与校准数据中的各类别均存在较大差异；当集合包含多个类别时，说明现有证据无法排除其中任一类别。后两种情况均不能形成唯一判断，可作为拒识依据。

需要区分接受率与共形覆盖率。接受率表示模型形成单一类别结论的样本比例；共形覆盖率表示真实类别包含在预测集合中的样本比例。在校准样本与测试样本满足可交换性条件时，共形预测具有有限样本覆盖性质。当数据采用时间划分或

存在分布变化时,该理论条件可能受到影响,因此还需要在测试集上报告总体和类别经验覆盖率。

2.9 本章小结

本章介绍了本文研究涉及的理论基础和关键技术。首先,说明了 APK 的基本结构和静态分析对象,并介绍 API 调用序列、程序调用图和 Manifest 声明信息三类静态模态。随后,结合三类数据的结构特点,介绍了 Transformer、GATv2 和前馈神经网络的基本原理。

在此基础上,本章说明了特征级、决策级和证据级多模态融合方式,分析了模态可信度评估所涉及的样本级信息状态、模型可见范围、跨模态支持关系和分支整体能力。最后,介绍了证据学习、主观逻辑、证据冲突处理、选择性预测和共形预测,为第 3 章的三模态可信度评估、第 4 章的可信证据融合以及第 5 章的类别条件共形拒识提供理论基础。

3 基于可观测证据的三模态可信度评估方法

API 调用序列、程序调用图和 Manifest 声明信息分别从行为顺序、程序结构和应用声明等角度描述安卓应用。由于三类模态的提取过程、表示形式和信息范围不同，其对同一样本所提供的判别依据并不总是同等充分。如果在融合过程中采用固定权重，信息不足或与其他模态联系较弱的分支仍可能对最终判断产生较大影响。

针对上述问题，本章提出一种基于可观测证据的三模态可信度评估方法。该方法首先从静态解析结果中提取模态可用性、模态完整性以及模态间支持关系，利用具有单调约束的校准器估计各分支在当前样本上的可靠性；随后结合分支在校准数据上的整体判别能力和编码器实际接收的信息比例，得到样本级模态可信评分。该评分不直接决定样本类别，而是用于调节第 4 章中各模态证据的保留程度。

3.1 问题描述与总体框架

第 2 章给出了三类静态模态及其编码方式。对于任一模态 $m \in \{\text{api}, \text{graph}, \text{man}\}$ ，本章将其在样本 x 上的可信评分记为：

$$T_m(x) \in [0,1] \quad (3-1)$$

可信评分用于衡量当前模态证据参与后续融合的适宜程度。评分越高，表示该模态在当前样本上具有较充分的可观测依据；评分越低，表示该模态可能存在不可用、信息不足、可见范围受限或跨模态支持较弱等情况。

三模态可信度评估过程如图 3-1 所示。




图 3-1 三模态可观测证据与可信度评估框架

Figure 3-1 Framework of Observable Evidence and Trustworthiness Assessment for Three Modalities

首先，从 APK 静态解析结果和编码过程记录中提取模态自身状态及模态间关系；其次，按照“数值越大、证据越可靠”的方向组织各模态的输入特征，并通过单调可靠性校准器估计样本级可靠性；最后，结合分支整体判别能力和模型可见比例，计算各模态的可信评分。

本章方法仅使用静态分析过程中能够直接记录或由解析结果计算得到的信息，不以人工设定的扰动强度作为输入，也不使用测试集标签。可靠性校准、能力先验估计和可见水平统计均在独立校准数据上完成，从而避免测试信息参与可信度建模。

3.2 可观测证据构建

模态可信度既与该模态自身的状态有关，也与其能否得到其他模态的支持有关。为此，本文从模态可用性、模态完整性、模型可见比例和跨模态关系四个方面构建可观测证据，并在此基础上估计分支整体判别能力。

3.2.1 模态可用性

模态可用性表示某一模态能否被成功提取并参与检测。对于模态 (m) ，其可用性定义为：

$$a_m(x) = \begin{cases} 1, & x_m \text{ is available,} \\ 0, & x_m \text{ is unavailable.} \end{cases} \quad (3-2)$$

API 模态仅在 DEX 解析成功且提取到有效 API 事件时可用；调用图模态要求 DEX 解析和图构建均成功、未发生超时且图中存在有效节点；Manifest 模态则要求配置文件解析成功并得到有效声明信息。模态可用性构成可信度评估中的硬约束。当 $a_m(x) = 0$ 时，对应模态的可信评分被置为 0，不再作为有效证据参与后续融合。

3.2.2 模态完整性

模态可用性只能区分“存在”与“缺失”，不能进一步反映可用信息是否充分。本文使用完整性评分 $q_m(x)$ 描述模态 m 的静态解析质量：

$$q_m(x) \in [0,1] \quad (3-3)$$

完整性评分由解析过程中的可观测元数据计算得到。为避免把样本本身规模较小误判为质量较低，完整性指标主要衡量解析是否成功、保留信息是否一致以及特征表示是否有效，而不直接奖励事件数量或图规模。

对于 API 模态，设 $r_{\text{dex}}(x)$ 表示 DEX 文件解析成功比例， $r_{\text{keep}}(x)$ 表示有效 API 事件保留比例， $r_{\text{count}}(x)$ 表示事件计数一致性， $r_{\text{type}}(x)$ 表示 API 类型覆盖率。首先，将上述信息加权组合为 API 事件质量评分：

$$Q_{\text{api}}(x) = w_0^a + w_1^a r_{\text{keep}}(x) + w_2^a r_{\text{count}}(x) + w_3^a r_{\text{type}}(x) \quad (3-4a)$$

在此基础上，API 模态完整性定义为：

$$q_{\text{api}}(x) = I_{\text{api}}(x) r_{\text{dex}}(x) Q_{\text{api}}(x) \quad (3-4b)$$

其中， $I_{\text{api}}(x)$ 表示 API 解析状态，解析成功时取 1，否则取 0； w_j^a 表示各项指标的权重，并满足：

$$w_j^a \geq 0, \quad \sum_{j=0}^3 w_j^a = 1. \quad (3-5)$$

$Q_{\text{api}}(x)$ 用于综合衡量 API 事件的保留情况、计数一致性和类型覆盖情况， $r_{\text{dex}}(x)$ 则用于反映多个 DEX 文件的整体解析情况。编码器最大输入长度造成的正常截断不计入 $r_{\text{keep}}(x)$ ，而是在第 3.3.3 节中通过模型可见比例单独修正，从而避免将编码器输入限制误判为 API 解析不完整。

调用图完整性综合考虑图解析状态、结构统计有效性、节点计数一致性以及图结构和节点特征的异常情况。设 $r_{\text{struct}}(x)$ 表示调用图结构统计是否有效， $r_{\text{count}}^g(x)$ 表示图节点数与方法数之间是否保持合理的计数关系。首先，将两项信息加权组合为调用图基础质量评分：

$$Q_{\text{graph}}(x) = w_0^g + w_1^g r_{\text{struct}}(x) + w_2^g r_{\text{count}}^g(x) \quad (3-6a)$$

设 $p_{\text{anom}}(x) \in [0,1]$ 表示调用图异常程度，用于反映严重节点孤立、严重结构碎片化、边丢失以及节点特征无效等情况。在此基础上，调用图完整性定义为：

$$q_{\text{graph}}(x) = I_{\text{graph}}(x) r_{\text{dex}}(x) Q_{\text{graph}}(x) (1 - p_{\text{anom}}(x)) \quad (3-6b)$$

其中， $I_{\text{graph}}(x)$ 表示调用图解析状态。当 DEX 文件和调用图均解析成功、图构建过程未发生超时或异常时， $I_{\text{graph}}(x) = 1$ ；否则取 0。各项权重满足：

$$w_j^g \geq 0, \quad \sum_{j=0}^2 w_j^g = 1. \quad (3-7)$$

$Q_{\text{graph}}(x)$ 用于衡量调用图解析结果的基础有效性， $p_{\text{anom}}(x)$ 则对明显的结构或特征异常进行修正。该指标不直接根据节点数量、边数量或图连通程度判断调用图质量，以避免将应用本身规模较小、调用关系稀疏等正常结构特征误判为图信息

不完整。编码器节点数上限造成的正常截断不计入 $p_{\text{anom}}(x)$ ，而是在第 3.3.3 节中通过模型可见比例单独处理。

对于 Manifest 模态，设 $r_{\text{vocab}}(x)$ 为声明词表覆盖率， $r_{\text{stat}}(x)$ 为权限、组件和意图等统计字段的有效性，则：

$$q_{\text{man}}(x) = I_{\text{man}}(x)(w_0^m + w_1^m r_{\text{vocab}}(x) + w_2^m r_{\text{stat}}(x)) \quad (3-8)$$

其中， $I_{\text{man}}(x)$ 表示 Manifest 是否成功解析， $w_j^m \geq 0$ 且 $\sum_j w_j^m = 1$ 。上述权重及异常判定范围在第 6 章实验设置中给出。

3.2.3 模态可见比例

静态解析得到的信息不一定全部进入编码器。API 调用序列受到最大序列长度限制，规模较大的调用图也可能受到最大节点数限制。若只依据解析完整性评估模态质量，便无法反映模型实际接收到的信息范围。为此，定义模态 (m) 的模型可见比例为：

$$v_m(x) \in [0,1] \quad (3-9)$$

对于 API 模态， $v_{\text{api}}(x)$ 为编码器实际接收的 API 事件数与预算截断前有效事件数之比；对于调用图模态， $v_{\text{graph}}(x)$ 为编码器实际接收的节点数与预算截断前有效节点数之比。Manifest 采用定长向量表示，因此令 $v_{\text{man}}(x) = 1$ 。

需要区分的是， $q_m(x)$ 描述静态解析结果本身的完整程度， $v_m(x)$ 描述编码器实际接收的信息比例。两者在可信度计算中分别承担可靠性估计和输入范围修正的作用，不在可靠性校准器中重复使用。

3.2.4 跨模态支持与不一致关系

模态自身信息充分并不意味着其一定能够得到其他模态的印证。本文进一步从 API 与调用图的结构对应关系，以及 Manifest 声明与代码行为的语义对应关系两个方面构建跨模态证据。

(1) API 调用与程序调用图的结构支持关系

API 调用序列和程序调用图均来源于 DEX 代码。API 事件发生于具体方法内部，调用图以方法为节点，因此可以利用 API 事件与方法节点之间的对应边衡量两类代码模态的结构联系。

设样本 x 中的有效 API 事件集合和调用图节点集合分别为 $A(x)$ 与 $G(x)$ ，二者的有效对应边集合为 $E_{ag}(x) \subseteq G(x) \times A(x)$ 。API 事件覆盖率定义为：

$$c_{api}(x) = \frac{|\{a \in A(x) \mid \exists g, (g, a) \in E_{ag}(x)\}|}{|A(x)|} \quad (3-10)$$

调用图节点覆盖率定义为：

$$c_{graph}(x) = \frac{|\{g \in G(x) \mid \exists a, (g, a) \in E_{ag}(x)\}|}{|G(x)|} \quad (3-11)$$

为同时考虑两个方向的覆盖情况，采用调和平均计算 API 与调用图之间的结构支持程度：

$$s_{ag}(x) = \begin{cases} \frac{2c_{api}(x)c_{graph}(x)}{c_{api}(x) + c_{graph}(x)}, & c_{api}(x) > 0 \wedge c_{graph}(x) > 0, \\ 0, & \text{otherwise.} \end{cases} \quad (3-12)$$

调和平均受两个方向中较低覆盖率的限制，可避免仅有少量 API 事件或图节点建立对应关系时产生过高的支持评分。

(2) Manifest 声明与代码行为的语义支持关系

Manifest 声明、API 事件和调用图节点具有不同的表示形式，难以进行逐项对应。本文将三类信息映射到统一的安全语义类别空间。设 Manifest 中出现的语义类别集合为 $S_{man}(x)$ ，API 和调用图对应的语义类别集合分别为 $S_{api}(x)$ 和 $S_{graph}(x)$ ，代码侧语义集合定义为：

$$S_{code}(x) = S_{api}(x) \cup S_{graph}(x) \quad (3-13)$$

Manifest 与代码之间的总体语义支持程度采用集合交并比计算：

$$s_{mc}(x) = \begin{cases} \frac{|S_{man}(x) \cap S_{code}(x)|}{|S_{man}(x) \cup S_{code}(x)|}, & |S_{man}(x) \cup S_{code}(x)| > 0, \\ 0, & \text{otherwise.} \end{cases} \quad (3-14)$$

为区分不一致关系的来源，进一步定义 Manifest 到代码方向的不一致程度：

$$d_{mc}(x) = \begin{cases} \frac{|S_{man}(x) \setminus S_{code}(x)|}{|S_{man}(x)|}, & |S_{man}(x)| > 0, \\ 0, & \text{otherwise,} \end{cases} \quad (3-15)$$

以及代码到 Manifest 方向的不一致程度：

$$d_{cm}(x) = \begin{cases} \frac{|S_{code}(x) \setminus S_{man}(x)|}{|S_{code}(x)|}, & |S_{code}(x)| > 0, \\ 0, & \text{otherwise.} \end{cases} \quad (3-16)$$

$d_{mc}(x)$ 较大，表示 Manifest 中存在较多未被代码侧观察结果支持的语义类别； $d_{cm}(x)$ 较大，则表示代码侧存在较多未在 Manifest 中得到支持的语义类别。上述指标描述静态证据之间的联系，不直接表示样本的良性或恶意类别。

当构成某一跨模态关系所需的模态缺失，或者相应关系没有被观察到时，该关系不应被解释为高度支持或高度冲突。本文将此类关系的有效值置为 0，并另外记录关系是否适用，以防止缺失关系向可靠性校准器提供错误的正向证据。

3.2.5 分支整体判别能力先验

样本级证据描述当前样本的信息状态，但不同模态分支的总体判别能力也可能存在差异。信息较完整的弱分支未必应当获得与强分支相同的作用。为此，本文根据独立校准数据上的分支性能构建能力先验。

设模态分支 m 在校准数据上的宏平均 F1 值为 P_m ，模态索引集合为 $\mathcal{M} = \{\text{api}, \text{graph}, \text{man}\}$ ，则能力先验定义为：

$$C_m = \min \left\{ 1, \max \left[C_{\min}, \frac{P_m}{\max_{j \in \mathcal{M}} P_j} \right] \right\} \quad (3-17)$$

其中， $C_{\min}$ 为能力先验下界。归一化后，性能最好的分支能力先验为 1，其余分支按照相对性能进行缩放。能力先验反映分支在数据集层面的总体判别水平，与样本级可观测证据形成互补。

表 3-1 汇总了本章使用的主要证据及其作用。

表 3-1 三模态可信度评估中的可观测证据

Table 3-1 Observable Evidence for Three-modality Trustworthiness Assessment

证据	符号	主要来源	作用
模态可用性	$a_m(x)$	解析状态与有效内容	排除不可用模态
模态完整性	$q_m(x)$	解析、保留与特征有效性	衡量模态自身质量
模型可见比例	$v_m(x)$	编码器实际输入范围	修正输入预算影响
结构支持	$s_{ag}(x)$	API 与方法节点对应边	衡量代码模态联系
语义支持	$s_{mc}(x)$	声明与代码语义集合	衡量跨源相互印证程
方向性不一致	$d_{mc}(x), d_{cm}(x)$	声明与代码语义差集	区分不一致来源
分支能力先验	C_m	校准数据上的分支性能	修正分支总体能力差异

3.3 三模态可信度估计

在可观测证据构建的基础上,本文依次进行样本级可靠性校准、模型可见性修正和综合可信评分计算。该过程分别从当前样本的信息状态、编码器实际输入范围和分支总体判别能力三个层面约束模态可信度。

3.3.1 模态证据向量

三类模态的证据来源并不完全相同,因此本文根据各模态特点分别组织可靠性校准输入。API 和调用图分支使用自身完整性、二者之间的结构支持程度以及 Manifest 与代码之间的语义支持程度; Manifest 分支除使用自身完整性和语义支持程度外,还使用两个方向上的语义一致程度。相应证据向量定义为:

$$o_{api}(x) = [q_{api}(x), s_{ag}(x), s_{mc}(x)]^T \quad (3-18)$$

$$o_{graph}(x) = [q_{graph}(x), s_{ag}(x), s_{mc}(x)]^T \quad (3-19)$$

$$o_{man}(x) = [q_{man}(x), s_{mc}(x), 1 - d_{mc}(x), 1 - d_{cm}(x)]^T \quad (3-20)$$

各维证据均按照数值越大、可靠性越高的方向组织,因此方向性不一致程度被转换为相应的一致程度。模态可用性作为最终可信评分的硬约束,模型可见比例则通过独立修正项参与计算,二者均不在可靠性校准器中重复输入。

3.3.2 单调可靠性校准

可观测证据反映模态信息状态,但不能直接等同于分支预测正确的可能性。本文分别为三个模态构建单调可靠性校准器,将证据向量映射为样本级可靠性评分:

$$R_m(x) = g_m(o_m(x)), \quad R_m(x) \in [0,1]. \quad (3-21)$$

其中, $g_m(\cdot)$ 为模态 m 对应的校准函数。为使输出变化符合可解释的证据方向,本文采用带非负权重约束的两层前馈网络。设网络中第 l 层的未约束权重为 $\bar{W}_m^{(l)}$, 实际参与计算的权重为:

$$W_m^{(l)} = \text{softplus}(\bar{W}_m^{(l)}) \quad (3-22)$$

则 $W_m^{(l)} \geq 0$ 。校准器可表示为:

$$R_m(x) = \sigma(W_m^{(2)} \text{softplus}(W_m^{(1)} o_m(x) + b_m^{(1)}) + b_m^{(2)}) \quad (3-23)$$

其中, $\sigma(\cdot)$ 为 Sigmoid 函数。由于权重非负、激活函数单调递增,当完整性、支持程度或一致程度提高而其他条件不变时, $R_m(x)$ 不会下降。

校准器以对应分支的预测正确性作为监督信号。设分支 m 对样本 x_i 的预测类别为 $\hat{y}_{m,i}$, 真实类别为 y_i , 则正确性标签为:

$$c_{m,i} = \mathbb{I}[\hat{y}_{m,i} = y_i] \quad (3-24)$$

设独立校准数据中模态 m 可用的样本数为 N_m ，并记 $R_{m,i} = R_m(x_i)$ ，其可靠性校准损失为：

$$\mathcal{L}_{\text{rel}}^{(m)} = -\frac{1}{N_m} \sum_{i=1}^{N_m} [c_{m,i} \log R_{m,i} + (1 - c_{m,i}) \log(1 - R_{m,i})] \quad (3-25)$$

不可用模态不参与相应分支的损失计算。通过该监督， $R_m(x)$ 表示在当前可观测证据条件下，分支 m 作出正确预测的估计可靠程度。

可靠性校准采用独立于模型选择和共形校准的数据子集。主体分类模型训练完成后，首先固定三个模态编码器及其分类头，再利用该子集拟合可靠性校准器。为使校准器能够学习模态信息状态变化与分支预测正确性之间的关系，除原始样本外，本文还分别构造 API、调用图和 Manifest 单模态退化视图。退化视图仅用于扩展校准阶段可观察到的证据状态，其退化类型和强度不作为校准器输入。由此，校准器仍然只依据完整性、结构支持和语义关系等可观测证据估计可靠性，同时避免校准目标反向干扰主体分类模型的训练。

3.3.3 模型可见性修正与综合可信评分

不同模态在正常样本上的可见比例可能不同。若直接使用绝对可见比例进行折扣，API 序列和调用图因正常输入预算产生的截断也可能被误判为异常。本文以独立校准数据中的正常可见水平为参照，只衡量当前样本相对于该水平的下降程度。

设模态 m 在校准数据上的可见比例中位数为：

$$\rho_m = \text{median}_{x_i \in \mathcal{D}_{\text{cal}}} v_m(x_i) \quad (3-26)$$

则样本 (x) 的相对可见比例定义为：

$$\bar{M}_m(x) = \min \left\{ \frac{v_m(x)}{\rho_m}, 1 \right\} \quad (3-27)$$

当当前样本的可见比例达到或超过校准数据的正常水平时， $\bar{M}_m(x) = 1$ ；当其低于正常水平时，该值随之减小。为避免局部信息减少导致模态作用被完全抑制，进一步引入下界参数 η 和形状参数 β ：

$$\tilde{M}_m(x) = \eta + (1 - \eta) \bar{M}_m(x)^\beta, \tilde{M}_m(x) \in [\eta, 1] \quad (3-28)$$

结合模态可用性 $a_m(x)$ 、分支能力先验 C_m 、样本级可靠性 $R_m(x)$ 和可见性修正因子 $\tilde{M}_m(x)$ ，最终可信评分定义为：

$$T_m(x) = a_m(x) C_m R_m(x)^\alpha \tilde{M}_m(x) \quad (3-29)$$

其中, $\alpha > 0$ 用于调节样本级可靠性的折扣强度。当 $0 < \alpha < 1$ 时, 可减弱多个可信度因素连续相乘造成的过度抑制。

式 (3-29) 从四个方面约束模态证据: $a_m(x)$ 判断模态能否参与融合; C_m 反映分支总体判别能力; $R_m(x)$ 刻画当前可观测证据对应的预测可靠性; $\tilde{M}_m(x)$ 修正编码器实际输入范围。任一模态不可用时, 其可信评分为 0; 模态可用但可靠性或可见比例下降时, 其评分相应降低。

图 3-2 给出了三模态可信评分的计算流程。该评分将在第 4 章中用于折扣各模态的类别证据, 使低可信模态减少对具体类别的支持, 而不是直接改变其预测类别。




图 3-2 三模态可信度评估流程

Figure 3-2 Trustworthiness Assessment Process for the Three Modalities

3.4 本章方法分析

本章方法的核心在于将三类静态模态的可信程度显式建模, 而不是默认所有模态在所有样本中同等可靠。与固定权重融合或简单特征拼接不同, 本文首先从 APK 静态解析过程中提取模态可用性、完整性、模型可见比例和跨模态支持关系等可观测证据, 然后结合分支整体判别能力先验, 得到样本级模态可信评分。

首先, 该方法能够刻画样本级模态质量差异。API 调用序列、程序调用图和 Manifest 声明信息虽然都属于静态特征, 但其来源和抽象方式不同。通过分别建模模态可用性和完整性, 模型能够识别某一模态在当前样本中是否提供了充分信息。

其次, 该方法考虑了模型实际可见的信息范围。对于长 API 序列或大规模调用图, 编码器可能无法接收全部原始信息。如果仅依据静态解析完整性评估模态

可信度，可能忽略模型输入预算带来的可见性差异。本文引入模型可见比例和相对可见性修正项，使可信度评估更贴近模型实际接收到的输入。

再次，该方法引入了跨模态支持关系。API 与调用图之间的对应关系、Manifest 与代码侧行为之间的支持关系，能够为判断模态证据是否充分提供辅助信息。相比仅使用单一模态自身质量，加入跨模态支持关系可以更好地反映多模态证据之间的可观测联系。

最后，该方法结合了分支整体判别能力先验。不同模态分支在数据集上的整体性能可能不同，单纯依赖样本级完整性可能导致模型过度相信一个完整但整体判别能力较弱的模态。通过引入校准集上的分支能力先验，本文方法能够同时考虑样本级质量和数据集级分支能力。

需要指出的是，本章得到的模态可信评分并不是模态真实可信度的绝对度量，而是基于可观测证据得到的估计结果。其作用不是直接决定最终类别，而是为后续证据折扣、冲突处理和低可信样本拒识提供基础。

3.5 本章小结

本章针对静态多模态检测中各模态信息状态和分支判别能力存在差异的问题，提出了基于可观测证据的三模态可信度评估方法。首先，从模态可用性、模态完整性、模型可见比例以及跨模态支持与不一致关系等方面构建可观测证据；其次，利用具有非负权重约束的单调校准器估计样本级可靠性，并根据独立校准数据获得分支能力先验和正常可见水平；最后，将模态可用性、分支能力、样本级可靠性和可见性修正统一为模态可信评分。第 4 章将在此基础上对三个模态的类别证据进行折扣和组合，以处理低可信模态及模态间判断冲突。

4 面向模态冲突的可信证据融合方法

第3章从模态自身信息质量、跨模态关系、分支整体判别能力和模型可见范围等方面，对 API 调用序列、程序调用图和 Manifest 声明信息进行了可信度评估，并获得了各模态在样本级别上的可信评分。在此基础上，本章研究不同模态分支的证据调整与组合方法。

三类静态模态具有不同的信息来源和抽象粒度，其分支模型对同一样本既可能形成一致判断，也可能支持不同类别。特征拼接、固定加权和概率平均等方法主要关注多模态信息的互补性，难以明确表示模态证据本身的不确定程度及不同模态之间的判断分歧。当某一模态可信度较低或多个模态意见冲突时，上述方法仍可能形成较为确定的分类结果。

针对这一问题，本章提出面向模态冲突的可信证据融合方法。首先，将三个模态分支的分类输出转换为由类别支持度和不确定程度构成的证据意见；其次，根据第3章得到的模态可信评分对各分支意见进行折扣，使可信度不足的类别支持转入不确定部分；最后，计算可信度折扣后、证据组合规则处理前的模态冲突，并采用 Yager 规则将该冲突计入融合不确定性。该方法在利用多模态共同证据的同时，能够降低低可信模态的影响，并保留不同模态判断不一致所反映的风险。

本文仅将 API 调用序列、程序调用图和 Manifest 声明信息视为具有明确来源边界的证据源。由三类模态共同计算得到的联合表示不具备与原始模态相互区分的信息来源，若将其作为第四路证据再次组合，将造成已有信息的重复使用。因此，联合表示不参与正式的证据学习、证据组合和最终分类决策。

4.1 问题描述与总体框架

设参与证据组合的模态集合为：

$$\mathcal{M} = \{\text{api}, \text{graph}, \text{man}\} \quad (4-1)$$

对于模态 $m \in \mathcal{M}$ ，其分支分类器输出类别得分，并进一步转换为证据意见 ω_m 。第3章得到的模态可信评分记为 $T_m(x)$ 。本章的目标是在保留各模态类别判断和不确定程度的基础上，利用 $T_m(x)$ 调节不同模态证据的作用，并对模态之间无法归入同一类别的证据进行处理，最终得到融合意见 ω^f 和融合类别概率 p^f 。

本章方法包括以下三个环节：

- (1) 将各模态分支输出转换为包含类别支持度和不确定程度的证据意见；

(2) 依据模态可信评分对分支意见进行折扣, 将因可信度不足而削弱的类别支持计入不确定部分;

(3) 计算折扣意见之间的组合前模态冲突, 并采用 Yager 规则完成三模态证据组合。

本章方法的总体流程如图 4-1 所示。




图 4-1 三模态证据调整与冲突保留融合框架

Figure 4-1 Three-modality Evidence Adjustment and Conflict-preserving Fusion Framework

4.2 三模态分支的证据表示

第 2 章介绍了证据学习和主观逻辑意见的基本形式。本章采用该表示描述 API、程序调用图和 Manifest 三个分支的分类结果。对于模态 m , 其证据意见记为:

$$\omega_m = (b_m, u_m) \quad (4-2)$$

其中, $b_m = [b_{m,1}, b_{m,2}, \dots, b_{m,K}]$ 表示模态 m 对各类别的支持程度, u_m 表示该模态未能明确分配给具体类别的不确定程度, 二者满足:

$$\sum_{k=1}^K b_{m,k} + u_m = 1 \quad (4-3)$$

本文研究良性与恶意二分类问题, 因此 $K = 2$ 。三个模态对应的证据意见分别记为 ω_{api} 、 ω_{graph} 和 ω_{man} 。与只输出类别概率的分支表示相比, 证据意见还保留了分支无法明确支持具体类别的部分, 为后续证据折扣和冲突处理提供了统一表示。

4.3 基于模态可信评分的证据折扣

模态可信评分 $T_m(x) \in [0,1]$ 表示模态 m 在样本 x 上的参考价值。为抑制低可信模态对融合结果的确定性影响，本文在证据组合之前对各模态意见进行可信度折扣。

对于类别 k ，折扣后的类别支持度定义为：

$$\tilde{b}_{m,k} = T_m(x)b_{m,k} \quad (4-4)$$

折扣后未继续分配给具体类别的部分计入不确定性。因此，折扣后的不确定程度为：

$$\tilde{u}_m = 1 - \sum_{k=1}^K \tilde{b}_{m,k} = 1 - T_m(x)(1 - u_m) \quad (4-5)$$

因此，折扣后的模态意见表示为：

$$\tilde{\omega}_m = (\tilde{\mathbf{b}}_m, \tilde{u}_m) \quad (4-6)$$

并满足：

$$\sum_{k=1}^K \tilde{b}_{m,k} + \tilde{u}_m = 1 \quad (4-7)$$

式（4-4）和式（4-5）表明，模态可信评分只调节各类别原有支持程度，不改变分支原有的类别方向。随着 $T_m(x)$ 降低，分配给具体类别的支持随之减少，相应部分转入不确定性。当模态不可用时，第3章定义的可信评分为0，此时 $\tilde{b}_m = 0$ 、 $\tilde{u}_m = 1$ ，该模态成为不携带类别倾向的空缺意见，不影响其他可用模态的组合结果。

4.4 组合前模态冲突的计算

可信度折扣能够减弱低可信模态的影响，但不同模态仍可能支持不同类别。为刻画三个折扣意见之间的判断分歧，本文在采用组合规则之前计算模态冲突程度。

对于类别 k ，三个模态能够共同归入该类别的交集支持为：

$$b_k^* = \prod_{m \in \mathcal{M}} (\tilde{b}_{m,k} + \tilde{u}_m) - \prod_{m \in \mathcal{M}} \tilde{u}_m \quad (4-8)$$

式（4-8）包含各模态直接支持类别 k 的部分，以及其他模态未明确支持具体类别的部分；所有模态均处于不确定状态的情况不计入类别支持。三个模态共同形成的不确定部分为：

$$u^* = \prod_{m \in \mathcal{M}} \tilde{u}_m \quad (4-9)$$

在类别交集支持和共同不确定部分之外，剩余证据来源于不同模态对互斥类别的支持。本文将其定义为组合前模态冲突：

$$\kappa(x) = 1 - \sum_{k=1}^K b_k^* - u^* \quad (4-10)$$

当三个模态主要支持相同类别时，能够归入类别交集支持的证据较多， $\kappa(x)$ 较小；当不同模态分别支持互斥类别时，无法归入同一类别的证据增加， $\kappa(x)$ 相应增大。该指标描述的是可信度折扣之后、组合规则处理之前的模态判断分歧，不用于判定某一模态必然错误，也不直接表示样本类别。第 5 章将进一步利用该冲突信息判断模型是否应当接受当前预测。

4.5 基于 Yager 规则的三模态证据融合

证据理论中的不同组合规则对冲突具有不同处理方式。Dempster 规则通过归一化将冲突从空集移除，并重新分配剩余证据。当多个模态意见较为一致时，该规则能够增强共同支持的类别；但在模态意见分歧较大时，归一化处理可能降低融合结果对组合前模态冲突的反映程度。

本文采用 Yager 规则组合三个折扣意见。该规则保留非冲突类别支持，并将组合前模态冲突 $\kappa(x)$ 计入融合不确定性。该规则保留非冲突类别支持，并将原始冲突计入融合不确定性。融合后的类别支持度和不确定性分别定义为：

$$b_k^f = b_k^* \quad (4-11)$$

$$u^f = u^* + \kappa \quad (4-12)$$

由此得到融合意见：

$$\omega^f = (\mathbf{b}^f, u^f) \quad (4-13)$$

其满足：

$$\sum_{k=1}^K b_k^f + u^f = 1 \quad (4-14)$$

由于 Yager 规则不满足一般意义下的结合律，依次进行两两组合可能使结果受到组合顺序影响。本文按照式 (4-8) 至式 (4-12) 同时计算三个模态的交集支持、共同不确定部分和冲突，从而使融合结果不依赖模态输入顺序。

为获得最终分类概率，本文按照统一类别基率将融合不确定性分配给各类别：

$$p_k^f = b_k^f + \frac{u^f}{K} \quad (4-15)$$

最终预测类别为：

$$\hat{y} = \operatorname{argmax}_k p_k^f \quad (4-16)$$

当三个模态意见较为一致时，交集支持集中于共同类别；当多个模态支持不同类别时，冲突被计入融合不确定性，而不被强制分配给某一类别。因此，融合意见能够同时反映分类倾向和模态分歧程度。

4.6 训练目标

本章方法的训练目标由融合分类损失、分支辅助分类损失和证据学习损失组成。

融合分类损失用于约束最终融合概率。对于包含 N 个样本的训练批次，其定义为：

$$\mathcal{L}_{\text{cls}} = -\frac{1}{N} \sum_{i=1}^N \log p_{i,y_i}^f \quad (4-17)$$

其中， p_{i,y_i}^f 表示样本 x_i 在真实类别 y_i 上的融合概率。

为保持三个模态分支的独立判别能力，本文分别对 API、程序调用图和 Manifest 分支施加辅助分类监督。设 $\mu \in [0,1]$ 为最低监督系数，则样本 x_i 对模态 m 的辅助监督权重为：

$$w_{m,i} = a_m(x_i)[\mu + (1 - \mu)q_m(x_i)] \quad (4-18)$$

模态 m 的加权辅助分类损失为：

$$\mathcal{L}_{\text{aux}}^{(m)} = -\frac{\sum_{i=1}^N w_{m,i} \log p_{m,y_i}(x_i)}{\sum_{i=1}^N w_{m,i}} \quad (4-19)$$

其中， $p_{m,y_i}(x_i)$ 表示模态分支 m 对真实类别的预测概率。不可用模态的权重为0；完整性较低但仍可用的模态保留最低监督强度，以避免分支在退化样本上完全失去分类学习信号。设当前批次中具有有效监督的模态集合为 $\mathcal{A}$ ，则三个分支的辅助损失按有效分支数取平均：

$$\mathcal{L}_{\text{aux}} = \frac{1}{|\mathcal{A}|} \sum_{m \in \mathcal{A}} \mathcal{L}_{\text{aux}}^{(m)} \quad (4-20)$$

证据学习损失用于约束各分支输出的狄利克雷证据。本文采用第 2 章所述的贝叶斯风险项和逐步退火的 KL 散度正则项，并在三个可用模态分支之间取平均：

$$\mathcal{L}_{\text{edl}} = \frac{1}{|\mathcal{A}|} \sum_{m \in \mathcal{A}} \mathcal{L}_{\text{edl}}^{(m)} \quad (4-21)$$

训练过程中采用类别平衡权重，并使 KL 散度项的系数随训练轮次逐步增加，以减弱训练初期过强证据约束对分类表征学习的影响。

综上，完整训练目标为：

$$\mathcal{L} = \mathcal{L}_{\text{cls}} + \lambda_{\text{aux}} \mathcal{L}_{\text{aux}} + \lambda_{\text{edl}} \mathcal{L}_{\text{edl}} \quad (4-22)$$

其中， λ_{aux} 和 λ_{edl} 分别表示分支辅助分类损失和证据学习损失的权重，具体取值在第 6 章实验设置中给出。

4.7 本章方法分析

本章方法将模态可信度评估、证据折扣和冲突处理组织为连续的融合过程，主要具有以下特点。

第一，三个模态分支均采用包含类别支持度和不确定程度的证据意见表示，使模态证据强弱和分支判断不确定性能够在同一框架下进行描述。

第二，模态可信评分在证据组合之前发挥作用。可信度不足所削弱的类别支持被计入不确定部分，而不会转移到其他类别，因而不会人为改变分支原有的类别判断方向。模态缺失时对应意见退化为空缺意见，能够从组合过程中自然消除其类别影响。

第三，三个模态通过一次性多源交集运算完成组合，避免了 Yager 规则两两组合可能产生的顺序依赖。不同模态无法归入同一类别的证据被保留为融合不确定性，使最终输出能够反映模态判断分歧。

第四，最终分类与后续拒识使用相互区分但相互关联的信息。分类决策依据 Yager 规则处理后的融合概率，第 5 章则使用组合规则处理之前的模态冲突评估预测风险，从而避免冲突在融合后被不确定性吸收而难以单独识别。

4.8 本章小结

本章针对安卓恶意软件多模态检测中模态可信程度存在差异、不同模态分支可能支持不同类别的问题，提出了面向模态冲突的可信证据融合方法。该方法将

API 调用序列、程序调用图和 Manifest 三个分支的分类结果表示为证据意见，并根据样本级模态可信评分进行折扣，使可信度不足所削弱的类别支持转入不确定部分。在此基础上，本文通过一次性三源交集运算计算类别支持、共同不确定部分和组合前模态冲突，并采用 Yager 规则将冲突保留在融合不确定性中。

本章方法在模态意见一致时能够累积共同支持的类别证据，在模态意见不一致时能够保留相应冲突，避免模态分歧在融合过程中被忽略。融合概率用于形成最终分类结果，组合前模态冲突则为第 5 章低可信预测处理提供风险信息，从而实现模态可信度评估、可信证据融合和预测风险控制之间的衔接。

5 面向低可信预测的类别条件拒识方法

第3章建立了基于可观测证据的三模态可信度评估方法，第4章进一步利用模态可信评分调节分支证据，并通过 Yager 规则完成三模态证据组合。经过上述处理，模型能够得到融合类别概率、融合不确定性和组合前模态冲突。其中，融合类别概率反映模型对良性和恶意类别的支持程度，组合前模态冲突反映不同模态分支在类别判断上的分歧程度。

常规分类模型需要对每个输入样本给出唯一类别。然而，当两个类别获得相近支持，或不同模态分支形成明显分歧时，最大概率对应的类别未必具有充分证据。对于此类样本，直接输出良性或恶意结论可能增加检测风险。更合理的处理方式是暂缓自动分类，并将样本交由动态分析、人工复核或其他检测流程进一步判断。

针对上述问题，本章提出面向低可信预测的类别条件共形拒识方法。该方法利用融合类别概率和组合前模态冲突构造类别非一致性分数，并在独立校准集上分别确定良性类和恶意类的共形阈值。测试阶段根据两个类别是否通过相应阈值检验构造预测集合，仅接受只包含一个类别的预测集合；当预测集合为空或同时包含两个类别时，拒绝自动分类。

5.1 问题描述与总体框架

设第4章得到的融合类别概率为：

$$\mathbf{p}^f(x) = [p_0^f(x), p_1^f(x)] \quad (5-1)$$

其中，类别0表示良性，类别1表示恶意。常规分类方法通常按照最大概率确定预测类别：

$$\hat{y}(x) = \arg \max_{k \in \{0,1\}} p_k^f(x) \quad (5-2)$$

该规则要求模型对全部样本给出唯一类别，但没有区分预测结果的可信程度。当两个类别的融合概率较为接近，或者不同模态对类别判断存在明显分歧时，最大概率对应的类别未必具有充分证据支持。

为此，本文在分类结果之外引入类别条件共形拒识机制。该方法包括以下三个步骤：

- (1) 针对良性和恶意两个候选类别分别构造非一致性分数；
- (2) 利用独立校准集分别确定两个类别的共形阈值；

(3) 根据测试样本形成的共形预测集合决定接受或拒识。

本章方法的总体流程如图 5-1 所示。




图 5-1 类别条件共形预测与拒识流程

Figure 5-1 Workflow of Class-conditional Conformal Prediction and Rejection

5.2 融合概率与模态冲突共同约束的非一致性分数

融合类别概率反映模型对各候选类别的支持程度，组合前模态冲突则反映不同模态意见之间的分歧。仅依据融合概率进行拒识，可能忽略不同模态形成该预测结果时是否存在明显分歧。因此，本文同时利用融合类别概率和组合前模态冲突构造类别非一致性分数。

设第 4 章定义的组合前模态冲突为 $\kappa(x)$ 。对于候选类别 c ，其非一致性分数定义为：

$$r_c(x) = 1 - p_c^f(x) + \kappa(x) \quad (5-3)$$

其中 $1 - p_c^f(x)$ 表示融合结果对类别 c 的支持不足程度， $\kappa(x)$ 表示不同模态意见在组合前的分歧程度。 $r_c(x)$ 越小，表示融合结果对类别 c 的支持越强且模态分歧越弱； $r_c(x)$ 越大，则表示该类别缺少充分支持，或不同模态之间存在较大冲突。

对于本文的二分类任务，两个候选类别的非一致性分数分别为：

$$r_0(x) = p_1^f(x) + \kappa(x) \quad (5-4)$$

$$r_1(x) = 1 - p_1^f(x) + \kappa(x) \quad (5-5)$$

上述分数分别针对良性和恶意两个候选类别计算，而不是只针对公式 (5-2) 得到的预测类别计算。非一致性分数用于样本排序和共形校准，不属于概率，其取值也不要求限制在 $[0,1]$ 内。

5.3 类别条件共形校准

为分别考察良性类和恶意类的覆盖情况，本文采用类别条件的划分共形校准方法。设独立校准集为：

$$\mathcal{D}_{\text{cal}} = \{(x_i, y_i)\}_{i=1}^{N_{\text{cal}}} \quad (5-6)$$

对于类别 $\setminus(c)$ ，选取校准集中真实标签为 $\setminus(c)$ 的样本，并计算其关于类别 $\setminus(c)$ 的非一致性分数：

$$\mathcal{R}_c = \{r_c(x_i) \mid (x_i, y_i) \in \mathcal{D}_{\text{cal}}, y_i = c\} \quad (5-7)$$

设集合 $\mathcal{R}_c$ 中包含 n_c 个分数，按升序排列为：

$$r_{c,(1)} \leq r_{c,(2)} \leq \cdots \leq r_{c,(n_c)} \quad (5-8)$$

给定显著性水平 α ，类别 c 的分位位置定义为：

$$k_c = \lceil (n_c + 1)(1 - \alpha) \rceil \quad (5-9)$$

当 $k_c \leq n_c$ 时，类别条件阈值定义为：

$$\tau_c = r_{c,(k_c)} \quad (5-10)$$

当 $k_c > n_c$ 时，令 $\tau_c = +\infty$ 。通过上述过程，良性类和恶意类分别得到阈值 τ_0 和 τ_1 。

类别条件校准分别依据两个类别的校准分数确定阈值，能够避免总体覆盖结果掩盖某一类别的覆盖不足。需要说明的是，本文对两个类别采用相同的显著性水平，因此该方法并未人为设置不同的类别误判代价，而是分别约束两个类别的经验覆盖情况。

在校准样本与测试样本满足可交换性条件时，类别条件共形预测对各类别具有有限样本覆盖性质：

$$\Pr\{Y \in \Gamma(X) \mid Y = c\} \geq 1 - \alpha \quad (5-11)$$

其中， $\Gamma(X)$ 表示测试样本对应的共形预测集合。实际覆盖情况仍需在测试集中通过经验指标进行验证。

5.4 共形预测集合与拒识规则

对于测试样本 $\setminus(x)$ ，分别计算其关于良性类和恶意类的非一致性分数，并将通过相应类别阈值检验的类别组成共形预测集合：

$$\Gamma(x) = \{c \in \{0,1\} \mid r_c(x) \leq \tau_c\} \quad (5-12)$$

根据集合 $\Gamma(x)$ 的大小，可以得到以下三种结果：

(1) 当 $|\Gamma(x)| = 1$ 时, 只有一个候选类别通过校准检验, 模型形成唯一类别结论;

(2) 当 $|\Gamma(x)| = 0$ 时, 两个候选类别均未获得充分支持, 当前样本与校准集中两类样本的预测模式均存在较大差异;

(3) 当 $|\Gamma(x)| = 2$ 时, 两个候选类别均通过检验, 模型无法排除其中任一类别, 因而不能形成唯一判断。

本文仅接受第一种情况, 拒识空集和双元素集合。接受函数定义为:

$$A(x) = \begin{cases} 1, & |\Gamma(x)| = 1, \\ 0, & |\Gamma(x)| \neq 1. \end{cases} \quad (5-13)$$

当 $A(x) = 1$ 时, 最终预测类别为集合 $\Gamma(x)$ 中的唯一元素; 当 $A(x) = 0$ 时, 样本进入后续复核流程。该规则同时检验两个候选类别, 不需要预先按照最大融合概率确定类别, 也不同于“根据预测类别选择一个阈值”的普通拒识方法。

5.5 本章方法分析

本章方法利用融合类别概率和组合前模态冲突构造类别非一致性分数, 并通过类别条件共形校准决定预测结果是否接受, 具有以下特点。

第一, 非一致性分数同时反映类别支持不足和组合前模态冲突。融合类别概率描述模型对候选类别的支持程度, 组合前模态冲突则保留不同模态意见之间的分歧信息。因此, 融合概率较高但模态意见存在明显冲突的样本仍可能被拒识。

第二, 分类过程与风险判断使用不同阶段的信息。第4章利用 Yager 规则将模态冲突计入融合不确定性, 以形成融合类别概率; 本章则直接使用组合前模态冲突 $\kappa(x)$ 参与共形校准, 从而使拒识机制能够保留对模态分歧的识别能力。

第三, 类别条件校准分别利用良性样本和恶意样本确定阈值, 能够避免总体覆盖结果掩盖单个类别的覆盖不足。由于两个类别采用相同显著性水平, 该方法的主要作用是分别约束类别覆盖, 而不是直接实现不同误判代价的优化。

第四, 共形预测集合能够区分唯一判断、证据不足和类别歧义。单元素集合对应唯一类别结论, 空集表示两个类别均缺少充分支持, 双元素集合表示两个类别均无法排除。这种输出形式为低可信样本的后续处理提供了明确依据。

第五, 本章与前两章构成连续的处理过程。第3章评估各模态的可信程度, 第4章利用可信评分完成证据折扣和冲突保留融合, 本章进一步利用融合类别概率与组合前模态冲突判断分类结果是否能够被自动接受。

5.6 本章小结

本章针对多模态证据不足或模态意见冲突时强制分类可能增加预测风险的问题，提出面向低可信预测的类别条件共形拒识方法。该方法针对良性和恶意两个候选类别，利用融合类别概率和组合前模态冲突分别构造类别非一致性分数；随后在独立校准集上确定类别条件阈值，并据此形成共形预测集合。

测试阶段仅接受只包含一个类别的预测集合，拒识空集和同时包含两个类别的集合。该方法在保留自动检测能力的同时，为证据不足和模态意见分歧较大的样本提供后续复核入口，并通过接受率、类别经验覆盖率、接受样本风险和恶意漏报等指标评价风险控制效果。

7 总结与展望

7.1 工作小结

Android 恶意软件检测面临样本持续演化、混淆对抗手段日趋复杂和单模态特征表达能力有限等挑战。现有多模态融合方法在跨模态语义对齐、模态质量差异自适应和训练鲁棒性等方面仍存在不足。针对上述问题，本文提出了一种融合显式对齐语义增强、质量感知鲁棒融合和复杂度感知训练框架的多模态 Android 恶意软件检测方法。本文的主要工作和贡献总结如下：

第一，提出了基于显式对齐的跨模态语义增强机制。针对现有多模态融合方法中跨模态注意力缺乏结构先验引导、注意力权重分散到无关区域的问题，本文利用 APK 反编译过程中天然可获取的方法字节跨度信息，构建了图像 tile 与程序图节点之间的显式对齐掩码，将其引入交叉注意力计算过程以约束注意力权重仅在语义对应的区域对之间传播。在此基础上，本文进一步引入基于跨模态监督对比学习的一致性约束和基于 EMA 更新的类别原型记忆机制，从类内聚合与跨模态对齐以及类别级锚点稳定两个层面增强共享嵌入空间的语义区分度。跨模态监督对比损失将同类所有样本纳入正样本集合，使一致性约束的梯度方向与原型记忆的类别中心聚拢目标天然一致，避免了传统 InfoNCE 方法中同类不同样本被推远所导致的梯度冲突。

第二，提出了质量感知的鲁棒多模态融合机制。针对真实场景中不同 APK 样本的图像模态和程序图模态质量存在显著差异、等权融合可能引入噪声干扰的问题，本文设计了质量感知门控融合机制。该机制综合利用图像 tile 保留比例、边保留比例和对齐掩码覆盖率等显式质量信号和编码器输出的学习特征，通过门控网络为每个样本动态生成模态融合权重，使质量较高的模态在融合过程中获得更大贡献。同时，本文引入基于梯度反转层的扰动类型判别器，通过对抗性约束抑制融合表示中残留的扰动类型信息，迫使模型学习对模态退化模式不变的判别特征。两者协同作用使融合过程具备了对模态质量差异的自适应调节能力。

第三，提出了复杂度感知的训练优化框架。针对 Android 应用样本在 DEX 数量、方法规模和结构复杂度等方面存在显著差异、传统均匀采样策略导致训练不稳定的问题，本文设计了复杂度感知的训练框架。该框架包含两个核心组件：基于 FFD 装箱算法的复杂度感知批采样策略，通过将复杂度相近的样本组织在同一 batch 中减小 batch 间的复杂度波动；以及从输入层、特征层到决策层的三级鲁棒优化策略，通过数据清洗与规整、多目标联合优化与阶段化权重调度、以及评估阶段低置信样本过滤机制，系统性地提升模型训练的稳定性和泛化能力。

第四，在时间一致评测设定下进行了系统实验验证。本文基于 AndroZoo 数据集，采用按年份划分的时间一致评测方式构建了涵盖 2018—2024 年的实验数据集，从整体对比、消融分析和鲁棒性分析三个维度对所提方法进行了系统验证。整体对比实验表明，本文方法在 Accuracy、Precision、Recall 和 Macro-F1

等指标上均优于单模态方法和多种多模态融合基线方法。消融实验验证了显式对齐掩码、一致性约束与原型记忆、显式质量信号、GRL 扰动抑制以及辅助分支监督各模块的有效性。鲁棒性实验表明，本文方法在图像模态退化和程序图模态受损条件下相较于最强基线方法表现出更小的性能衰减幅度，验证了质量感知融合和鲁棒训练机制在模态退化场景下的协同保护作用。

7.2 不足与展望

尽管本文方法在实验中取得了较好的性能，但仍存在一些局限性，未来研究可从以下方向进行改进和拓展：

（1）模态类型的拓展。本文仅利用了字节级可视化图像和函数调用图两种模态。Android 应用中还包含权限声明、组件配置、API 调用序列、网络通信行为等丰富的多源信息。未来工作可以考虑将更多类型的特征信息作为新的模态引入融合框架，进一步丰富多模态表示的信息来源。同时，如何在模态数量增加后仍保持高效的跨模态对齐和质量感知融合，是值得深入研究的问题。

（2）动态分析信息的融合。本文方法基于静态分析提取特征，能够在不执行 APK 的条件下完成检测，具有部署便捷和效率较高的优势。然而，静态分析难以有效应对运行时动态加载、反射调用和加壳保护等高级逃逸技术。未来工作可以探索将动态分析信息（如运行时 API 调用序列、系统调用轨迹、网络行为日志等）作为补充模态引入框架，结合静态特征和动态行为特征构建更为全面的检测能力。如何在保证检测效率的前提下有效融合静态和动态两类信息，是需要重点解决的挑战。

（3）持续学习与概念漂移适应。本文通过时间一致评测设定验证了模型在跨年份样本上的泛化能力，但模型一旦部署后即处于静态状态，无法自主适应恶意软件家族的持续演化和新型攻击模式的出现。未来工作可以探索将持续学习或增量学习机制引入多模态检测框架，使模型能够在接收新样本后进行高效更新，同时避免对历史知识的灾难性遗忘。此外，如何检测和量化概念漂移的发生，并据此触发模型的自适应调整，也是提升实际部署效果的重要方向。

（4）可解释性增强。本文方法在融合过程中使用了交叉注意力权重和质量门控权重等中间结果，这些信息具有一定的可解释性潜力，但尚未在本文中进行系统的可解释性分析。未来工作可以考虑对注意力权重分布、门控决策过程和关键特征区域进行可视化和归因分析，帮助安全分析人员理解模型的判别依据，提

升检测结果的可信度和实用性。特别是在恶意软件家族分析和变种溯源等应用场景中，可解释性能力具有重要的实际价值。

（5）轻量化与部署效率优化。本文方法涉及双编码器特征提取、交叉注意力融合、门控网络计算和对抗训练等多个模块，整体计算开销较高。对于需要在移动设备端或资源受限环境中部署的场景，模型的推理效率和内存占用是重要的约束条件。未来工作可以探索知识蒸馏、模型剪枝、量化压缩等轻量化技术，在尽量保持检测性能的前提下降低模型的计算和存储需求，使其更适合实际部署需求。

参考文献

- [1] Google. Google Play's efforts to protect users in 2024[R/OL]. (2025-01-29) [2025-03-15]. <https://security.googleblog.com/2025/01/how-we-kept-google-play-and-android-users-safe-2024.html>.
- [2] Kaspersky. Mobile threats in 2024[R/OL]. (2025-02-26) [2025-03-15]. <https://securelist.com/mobile-threat-report-2024/115518/>.
- [3] Allix K, Bissyandé T F, Klein J, et al. AndroZoo: Collecting millions of Android apps for the research community[C]. //Proc. of the 13th International Conference on Mining Software Repositories (MSR), Austin, TX, 2016. New York: ACM, 2016: 468-471.
- [4] Arp D, Spreitzenbarth M, Hübner M, et al. DREBIN: Effective and explainable detection of Android malware in your pocket[C]. //Proc. of the 21st Annual Network and Distributed System Security Symposium (NDSS), San Diego, CA, 2014. Reston: Internet Society, 2014: 1-15.
- [5] Mariconti E, Onwuzurike L, Andriotis P, et al. MaMaDroid: Detecting Android malware by building Markov chains of behavioral models extended version[J]. ACM Transactions on Privacy and Security, 2019, 22(2): 1-34.
- [6] Pendlebury F, Pierazzi F, Jordaney R, et al. TESSERACT: Eliminating experimental bias in malware classification across space and time[C]. //Proc. of the 28th USENIX Security Symposium, Santa Clara, CA, 2019. Berkeley: USENIX Association, 2019: 729-746.
- [7] Singh J, Singh J. A survey on machine learning-based malware detection in executable files[J]. Journal of Systems Architecture, 2021, 112: 101861.
- [8] Arrowsmith C, Vidal J M, Carlin D, et al. MalPhase: Fine-grained malware detection using conditional GANs and gradient-based explanations with multi-modal data fusion[C]. //Proc. of IEEE INFOCOM 2024 Workshops, Vancouver, BC, 2024. Piscataway: IEEE, 2024: 1-6.
- [9] Tanveer M, Luo S, Barua A, et al. Deep multi-modal learning for Android malware detection using graph neural networks and image features[J]. Neural Computing and Applications, 2024, 36: 20639-20657.
- [10] Xu K, Li Y, Deng R H, et al. DroidEvolver: Self-evolving Android malware detection system[C]. //Proc. of IEEE European Symposium on Security and Privacy (EuroS&P), Genoa, Italy, 2019. Piscataway: IEEE, 2019: 47-62.
- [11] Wu S, Zhang Y, Li D, et al. Android malware detection based on enhanced features of function call graph using GCN[J]. Computers & Security, 2023, 131: 103295.
- [12] 王志文, 李清宝, 王剑锋, 等. 基于图卷积网络的 Android 恶意软件检测方法[J]. 计算机研究与发展, 2023, 60(5): 1096-1107.
- [13] 孟宪翌, 李峰. 基于异构图 Transformer 和关键节点筛选的 Android 恶意软件检测方法[J]. 通信学报, 2023, 44(8): 157-168.
- [14] Zhao Z, Tang B, Gao J, et al. DroidFSG: Android malware detection based on frequent subgraph mining[J]. Journal of Information Security and Applications, 2023, 74: 103460.
- [15] Guo W, Mu D, Wu Y, et al. Android malware detection via hierarchical attention-based graph neural network[J]. Computers & Security, 2023, 128: 103157.

- [16] 黄诚, 李阳, 齐斌, 等. 基于可疑子图驱动的可解释 Android 恶意软件检测框架[J]. 软件学报, 2024, 35(4): 1892-1910.
- [17] Liu Z, Wang R, Japkowicz N, et al. Android malware detection with network traffic graph[J]. Computers & Security, 2024, 138: 103673.
- [18] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. //Proc. of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Las Vegas, NV, 2016. Piscataway: IEEE, 2016: 770-778.
- [19] Kipf T N, Welling M. Semi-supervised classification with graph convolutional networks[C]. //Proc. of the 5th International Conference on Learning Representations (ICLR), Toulon, France, 2017: 1-14.
- [20] Brody S, Alon U, Yahav E. How attentive are graph attention networks?[C]. //Proc. of the 10th International Conference on Learning Representations (ICLR), Virtual, 2022: 1-26.
- [21] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]. //Proc. of the 31st Conference on Neural Information Processing Systems (NeurIPS), Long Beach, CA, 2017: 5998-6008.
- [22] Oord A, Li Y, Vinyals O. Representation learning with contrastive predictive coding[J]. arXiv preprint arXiv:1807.03748, 2018.
- [23] Ganin Y, Ustinova E, Ajakan H, et al. Domain-adversarial training of neural networks[J]. Journal of Machine Learning Research, 2016, 17(59): 1-35.
- [24] Srivastava N, Hinton G, Krizhevsky A, et al. Dropout: A simple way to prevent neural networks from overfitting[J]. Journal of Machine Learning Research, 2014, 15(1): 1929-1958.
- [25] Bengio Y, Louradour J, Collobert R, et al. Curriculum learning[C]. //Proc. of the 26th International Conference on Machine Learning (ICML), Montreal, Canada, 2009. New York: ACM, 2009: 41-48.
- [26] Katharopoulos A, Fleuret F. Not all samples are created equal: Deep learning with importance sampling[C]. //Proc. of the 35th International Conference on Machine Learning (ICML), Stockholm, Sweden, 2018. PMLR, 2018: 2525-2534.
- [27] Khosla P, Teterwak P, Wang C, et al. Supervised contrastive learning[C]. //Proc. of the 34th Conference on Neural Information Processing Systems (NeurIPS), Virtual, 2020: 18661-18673.
- [28] Guo C, Pleiss G, Sun Y, et al. On calibration of modern neural networks[C]. //Proc. of the 34th International Conference on Machine Learning (ICML), Sydney, Australia, 2017. PMLR, 2017: 1321-1330.
- [29] Nataraj L, Karthikeyan S, Jacob G, et al. Malware images: Visualization and automatic classification[C]. //Proc. of the 8th International Symposium on Visualization for Cyber Security (VizSec), Pittsburgh, PA, 2011. New York: ACM, 2011: 1-7.
- [30] Baltrusaitis T, Ahuja C, Morency L P. Multimodal machine learning: A survey and taxonomy[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2019, 41(2): 423-443.
- [31] Kittler J, Hatef M, Duin R P W, et al. On combining classifiers[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1998, 20(3): 226-239.

- [32] Lu J, Batra D, Parikh D, et al. ViLBERT: Pretraining task-agnostic visiolinguistic representations for vision-and-language tasks[C]. //Proc. of NeurIPS, Vancouver, Canada, 2019: 13-23.
- [33] Pascanu R, Mikolov T, Bengio Y. On the difficulty of training recurrent neural networks[C]. //Proc. of the 30th International Conference on Machine Learning (ICML), Atlanta, GA, 2013. PMLR, 2013: 1310-1318.
- [34] 李航. 统计学习方法[M]. 第2版. 北京: 清华大学出版社, 2019: 1-25.
- [35] 周志华. 机器学习[M]. 北京: 清华大学出版社, 2016: 171-196.

附录 A

[附录标题]

[内容为五号宋体。] 附录是作为论文主体的补充项目，并不是必须的。
论文的附录依序用大写正体英文字母 A、B、C……编序号，如：附录 A。

索引

[内容为五号宋体。] 按照需要编排分类索引、著者索引、关键词索引等。

作者简历及攻读硕士/博士学位期间取得的研究成果

[内容采用五号宋体] 包括教育经历、工作经历、攻读学位期间发表的论文和完成的工作等。行距 16 磅，段前后各为 0 磅。

一、作者简历

二、发表论文

[1]

[2]

[3]

·

·

·

三、参与科研项目

[1]

[2]

[3]

·

·

·

四、专利

[1]

[2]

[3]

·

·

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作和取得的研究成果，除了文中特别加以标注和致谢之处外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京交通大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

学位论文作者签名：

签字日期：

年 月 日

学位论文数据集

表 1.1: 数据集页

关键词*	密级*	中图分类号	UDC	论文资助
学位授予单位名称*		学位授予单位代码*	学位类别*	学位级别*
北京交通大学		10004		
论文题名*		并列题名*		论文语种*
作者姓名*			学号*	
培养单位名称*		培养单位代码*	培养单位地址	邮编
北京交通大学		10004	北京市海淀区西直门外上园村 3 号	100044
专业学位类别（领域）*		研究方向*	学制*	学位授予年*
论文提交日期*				
导师姓名*			职称*	
评阅人	答辩委员会主席*		答辩委员会成员	
电子版论文提交格式 文本（ ） 图像（ ） 视频（ ） 音频（ ） 多媒体（ ） 其他（ ） 推荐格式：application/msword; application/pdf				
电子版论文出版（发布）者		电子版论文出版（发布）地		权限声明
论文总页数*				
共 33 项，其中带*为必填数据，为 21 项。				